第三章：模型输出——跨越"文本"与"结构"的鸿沟

3.1 引言：为什么大模型的输出是个"黑盒"?

在 AI Agent 的开发中，我们希望大模型（LLM）像一个严谨的程序员一样输出数据，例如：

```
{"action": "search", "query": "今天的天气"}
```

但现实是，LLM 本质上是一个"下一个词预测器"，它更喜欢自然语言。它可能输出：

> "好的，帮您查询天气。以下是调用的参数：`{"action": "search", "query": "今天的天气"}`，请注意查收。" 这种"喋喋不休"对人类友好，但对程序调用是灾难。**本章的核心任务，就是设计一套严密的流水线，将模糊的自然语言转化为程序可信赖的结构化对象（如 JSON）。**

3.2 核心挑战：输出不稳定的四大元凶

在生产环境中，直接使用 `json.loads(model_output)` 往往会失败，原因通常有以下四点：

1. **格式包裹**：模型喜欢在代码块前后加解释性文字（如 "Sure! Here is..."）。
2. **语法错误**：模型可能漏掉逗号、括号不匹配，尤其在 JSON 很长时。
3. **Token 截断**：受到 `max_tokens` 限制，JSON 输出到一半被强行截断，导致残缺。
4. **格式漂移**：你想要 JSON，它却给了你 Markdown 表格或 XML。

3.3 解决方案：从"预防"到"治疗"

要解决上述问题，我们需要构建三层防御体系：**约束层、解析层、修复层**。

3.3.1 第一道防线：约束层（预防）

在 Prompt 和模型层面强制输出格式。

- **Prompt 强约束**：
  - 明确指令："仅输出 JSON，不要包含任何解释性文字。"
  - 使用 Few-shot（少样本提示）给出标准范例。
  - **技巧**：使用特殊标记（如 `<JSON>` 和 `</JSON>`）包裹数据，便于正则提取。
- **模型原生能力**：
  - **JSON Mode**：调用 API 时设置 `response_format={"type": "json_object"}`，强制模型输出合法 JSON 字符串。
  - **Structured Outputs (Strict Mode)**：更高级的功能（如 OpenAI 的 JSON Schema 约束），直接提供数据模型，模型保证字段齐全且类型正确。

3.3.2 第二道防线：解析层（治疗）

即便使用了约束，模型仍可能"犯错"。我们需要一个鲁棒的解析器来清洗数据。

设计思路

解析器不应假设输入是纯净的，而应像做手术一样，从杂乱的文本中"切除"有效的 JSON 结构。

> 💡 **程序🟣碎碎念：我让AI输出JSON，它给了我一首诗。我让它输出结构化数据，它给了我一首诗。我让它别说话直接给JSON，它给了我一首诗+JSON。我让它不要诗，它问我"那您想要什么样的诗风？"。我：.....（已上天台）# 论如何气死一个程序员#**

流程设计

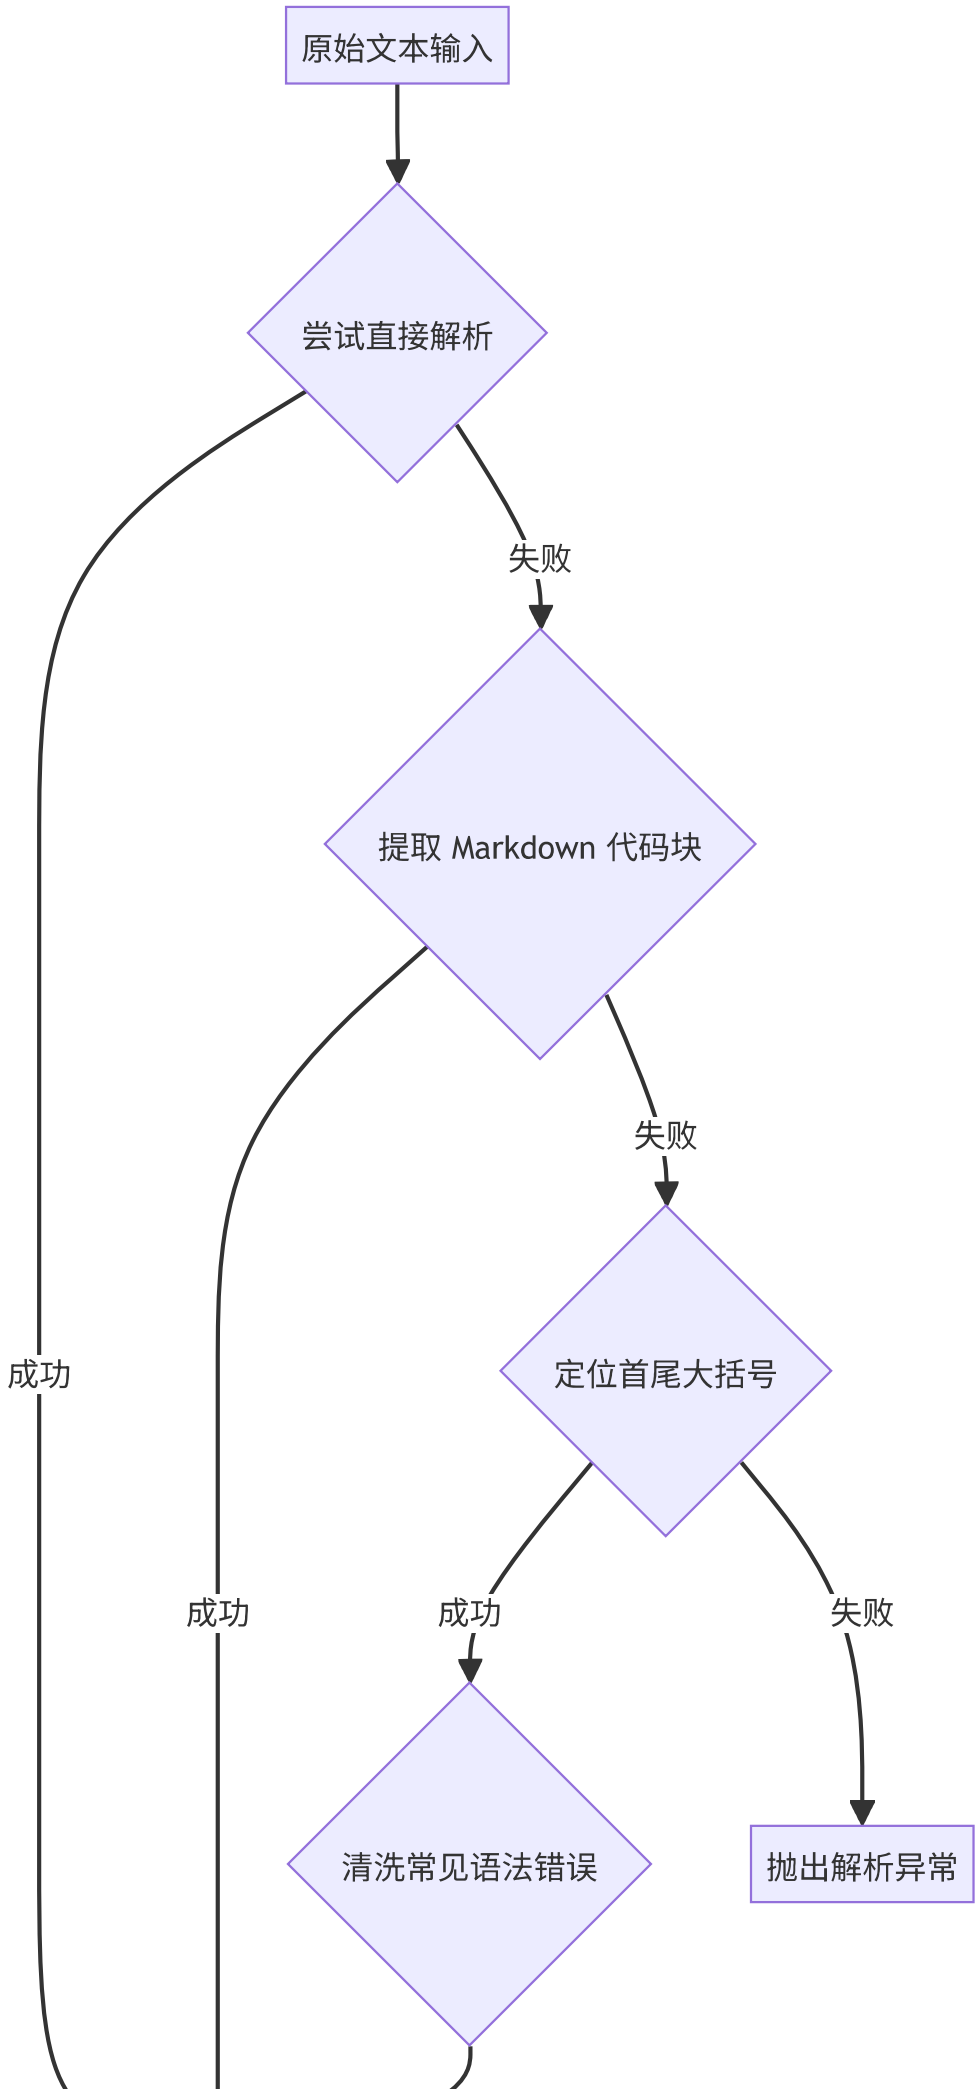
原始文本输入
尝试直接解析
失败
成功
提取 Markdown 代码块
失败
成功
定位首尾大括号
成功
失败
清洗常见语法错误
抛出解析异常

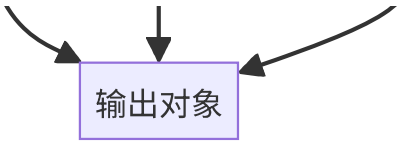

具体代码实现

```
 import re
import json
def robust_json_parse(text):
    """
    鲁棒的 JSON 解析器：能够处理包裹文本、Markdown 代码块及部分语法错误。
    """
    # 步骤 1: 尝试直接解析
    try:
        return json.loads(text)
    except json.JSONDecodeError:
        pass # 继续尝试更复杂的方法
    # 步骤 2: 尝试提取 Markdown 代码块 (```json ... ```)
    # 正则解释：匹配 ```json 或 ``` 包裹的内容
    pattern = r"```(?:json)?\s*([\s\S]*?)\s*```"
    match = re.search(pattern, text)
    if match:
        try:
            return json.loads(match.group(1))
        except json.JSONDecodeError:
            pass # 即使提取出代码块，内部仍可能语法错误，继续下一步
    # 步骤 3: "外科手术式"提取 —— 寻找第一个 '{' 和最后一个 '}'
    start = text.find('{')
    end = text.rfind('}')
    if start != -1 and end != -1 and end > start:
        json_str = text[start:end+1]

        # 步骤 4: 修复常见语法错误 (如尾随逗号 {"a": 1,} -> {"a": 1})
        # 注意：这是一个简单的修复，生产环境建议使用 json repair 库
        cleaned_str = json_str.replace(",}", "}").replace(",]", "]")
        try:
            return json.loads(cleaned_str)
        except json.JSONDecodeError:
            pass
    raise ValueError("无法从输出中解析出有效的 JSON 对象")
# 测试用例
test_cases = [
    '{"name": "Alice", "age": 30}', # 标准情况
    '好的，这是结果：```json\n{"name": "Bob"}\n```', # Markdown 包裹
    'Start text {"name": "Charlie", } end text', # 带前后缀与尾随逗号
]
for text in test_cases:
    print(f"输入: {text}")
    print(f"解析结果: {robust_json_parse(text)}\n")
```

3.3.3 第三道防线：高级难题（流式与截断）

在 Agent 需要实时反馈的场景（如打字机效果），流式输出给解析带来了巨大挑战：JSON 是在未完成状态下传输的，如何解析半个 JSON?

1. 流式 JSON 处理策略

核心痛点： `json.loads` 需要完整的字符串，而流式传输只有碎片。 **解决方案：**

- **UI 层**：前端随流式输入实时渲染 Markdown。
- **工具调用层**：必须等待结构完整。
- **技术实现**：使用 `partial_json` 库或监控闭合符号。 **设计流程图**：

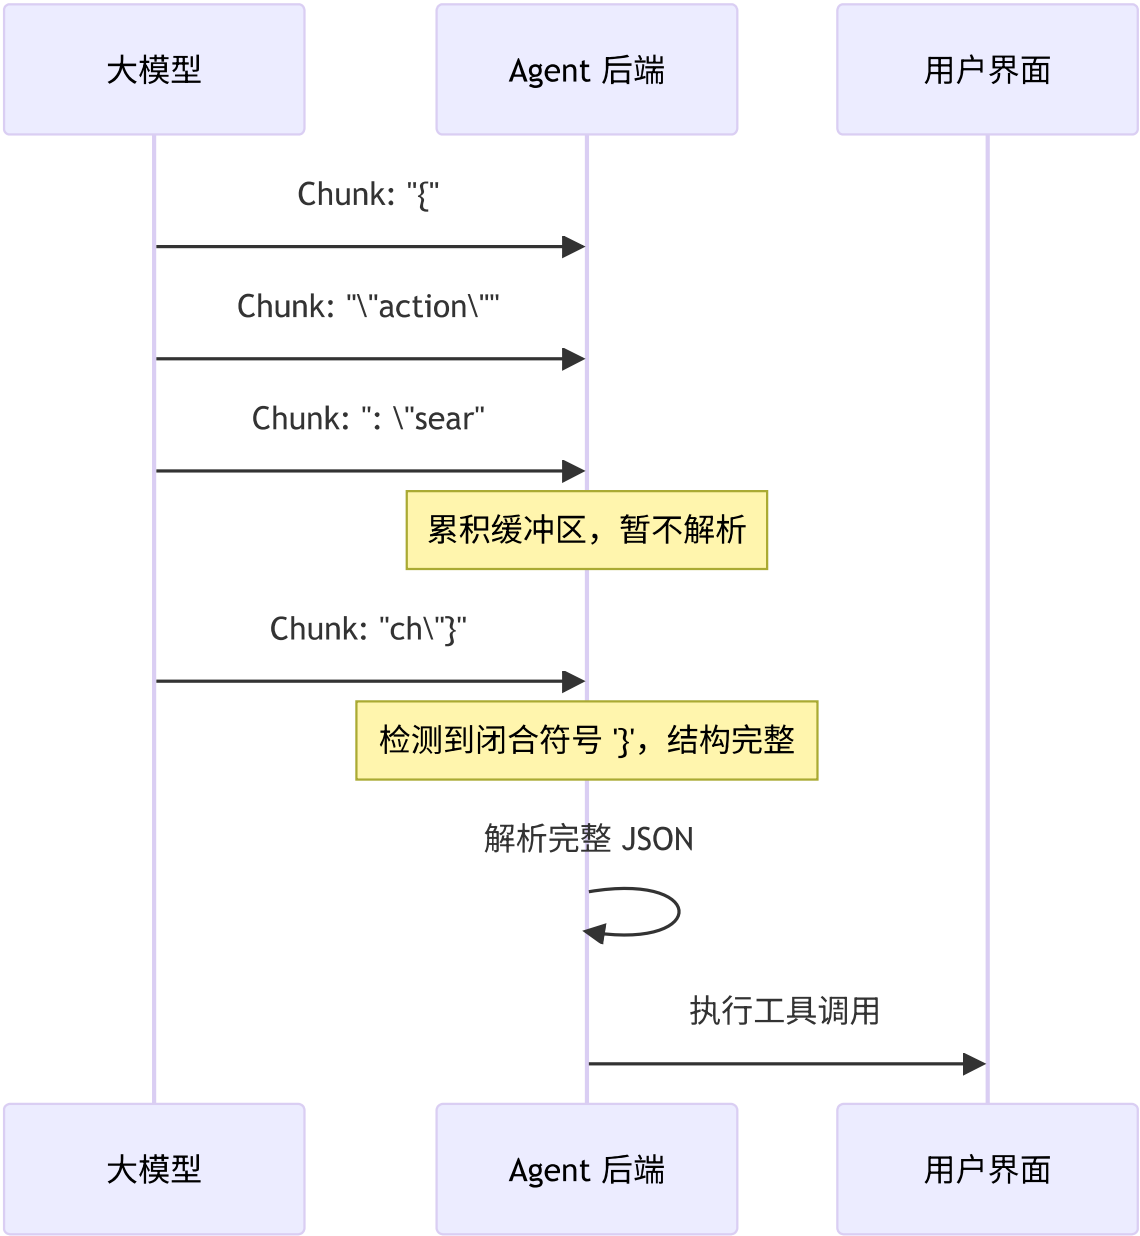

2. 输出截断的急救

如果 LLM 输出触达 `max_tokens` 限制，JSON 会变成 `{"long_list": [1, 2, 3` 这样残缺不全。

- **检测机制**：检查 API 返回的 `finish_reason` 。如果是 `length` ，则说明输出未完成。
- **修复策略**：
  1. **自动补全**：如果是简单的列表或对象，尝试通过正则补全缺失的括号 `]}` 。
  2. **自动续写**：将截断的 JSON 作为上下文，发送 Prompt："请补全以下未完成的 JSON："，让模型继续生成。
  3. **降级处理**：如果关键字段缺失，直接抛出异常，触发 Agent 的重试机制。

3.4 闭环系统：数据校验与自我修复

解析成功只是第一步，数据类型对不对？必填项有没有？我们需要引入 **Pydantic** 进行强校验，并构建"自我修复循环"。

3.4.1 Pydantic 强校验

使用 Pydantic 定义数据模型，确保字段类型和必填项符合预期。

```
 from pydantic import BaseModel, ValidationError
class AgentAction(BaseModel):
    tool_name: str
    parameters: dict
# 模拟解析出的数据（类型错误）
raw_data = {"tool_name": 12345, "parameters": "invalid_string"}
try:
    # Pydantic 会尝试自动转换类型，如果失败则抛出 ValidationError
    action = AgentAction(**raw_data)
except ValidationError as e:
    print(f"校验失败详情: {e}")
    # 这里触发自我修复逻辑
```

3.4.2 自我修复循环

当解析失败或校验不通过时，不要直接报错。利用 LLM 的上下文理解能力，让它自己修正错误。 **设计流程：**

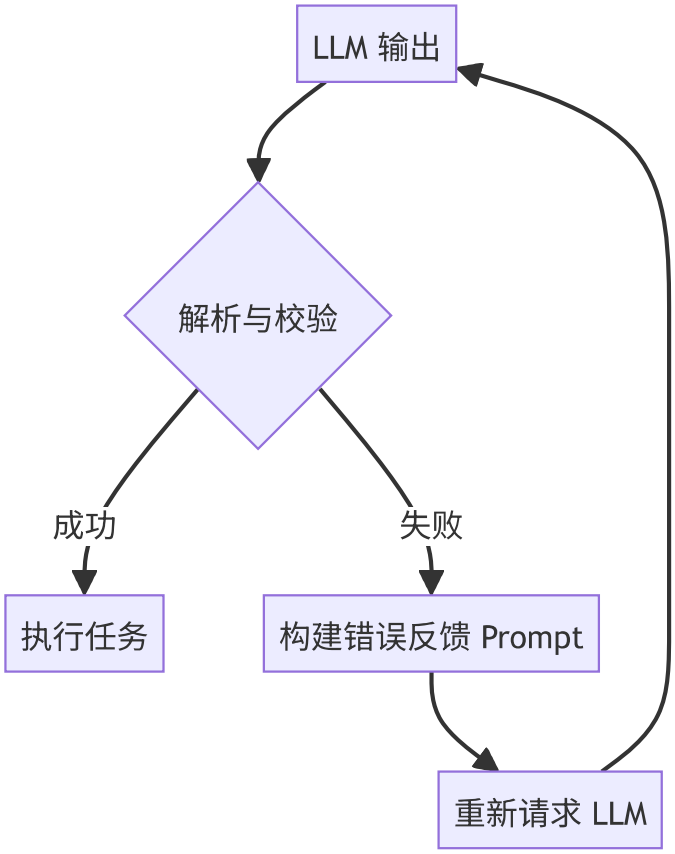

具体步骤示例：

1. **首次尝试：**LLM 输出 `{'tool': 'search', 'param': 'weather'}` ，但 Prompt 要求的是 `parameters` 字段。
2. **捕获错误：**Pydantic 报错 `Missing field 'parameters'` 。
3. **构建反馈 Prompt：**

   > "你之前的输出格式有误。错误信息： `Missing field 'parameters'` 。 请修正并重新输出。注意：不要输出任何解释，直接输出修正后的 JSON。"

4. **重试：**LLM 看到错误信息，修正输出为 `{'tool': 'search', 'parameters': {'query': 'weather'}}` 。 这种闭环机制能将解析成功率从 90% 提升至 99% 以上。

3.5 本章小结

解析和格式化是连接 LLM "思维"与系统"行动"的桥梁。本章我们从最简单的 `json.loads` 出发，构建了一套工业级的输出处理方案：

1. **预防**：通过 JSON Mode 和 Prompt 约束减少错误。
2. **解析**：编写鲁棒的代码清洗 Markdown 和多余文本。
3. **急救**：处理流式输出与截断异常。
4. **闭环**：结合 Pydantic 校验与自我修复循环，确保数据万无一失。 下一章，我们将利用本章解析出的结构化数据，赋予 Agent 真正的能力——**Function Calling（函数调用）**，让它去驱动真实世界的工具。

3.6 补充内容：工程化实践要点

3.6.1 类型安全与代码健壮性

常见问题场景： 生产环境中，LLM偶尔会返回格式错误的JSON，导致整个服务崩溃。排查问题时发现代码中大量使用 `dict` 类型，缺乏类型提示，无法快速定位问题。

解决思路与方案：

```
 from pydantic import BaseModel, Field, validator
from typing import Optional, List, Dict, Any

class ToolCallRequest(BaseModel):
    """工具调用的请求结构"""
    tool name: str = Field(..., description="工具名称")
    parameters: Dict[str, Any] = Field(default_factory=dict, description="工具参数")

    @validator('tool_name')
    def validate tool name(cls, v):
        if not v or not v.replace('_', '').isalnum():
            raise ValueError("工具名称只能包含字母、数字和下划线")
        return v

class AgentAction(BaseModel):
    """Agent执行的动作"""
    action_type: str = Field(..., description="动作类型: tool_call/text")
    tool_call: Optional[ToolCallRequest] = None
    text_response: Optional[str] = None

    class Config:
        # 确保action_type和对应字段一致
        validate_assignment = True
```

- **Pydantic模型定义：**使用Pydantic定义强类型的数据模型。
- **类型注解：**为所有函数添加完整的类型注解。
- **运行校验：** `validate_assignment=True` 确保赋值时也进行类型检查。

3.6.2 单元测试策略

常见问题场景： 每次修改解析逻辑都担心影响现有功能，但手动测试覆盖不了所有边界情况。上线后频繁出现因解析错误导致的Bug。

解决思路与方案：

```
 import pytest
from my_parser import robust_json_parse, OutputParser

class TestRobustJsonParser:
    """JSON解析器的单元测试"""

    def test standard json(self):
        """测试标准JSON解析"""
        result = robust_json_parse('{"name": "Alice", "age": 30}')
        assert result == {"name": "Alice", "age": 30}

    def test_markdown_code_block(self):
```

```
        """测试Markdown代码块包裹的JSON"""
        result = robust_json_parse("```json\n{\"name\": \"Bob\"}\n```")
        assert result == {"name": "Bob"}

    def test_trailing_comma(self):
        """测试带尾随逗号的不合法JSON"""
        result = robust_json_parse('{"name": "Charlie", }')
        assert result == {"name": "Charlie"}

    def test_invalid_json_raises_error(self):
        """测试无效JSON抛出正确异常"""
        with pytest.raises(ValueError, match="无法解析"):
            robust_json_parse("not json at all")

    @pytest.mark.parametrize("input_str,expected", [
        ('{"a": 1}', {"a": 1}),
        ('text {"b": 2} more', {"b": 2}),
        ('{"c": "hello"}', {"c": "hello"})
    ])
    def test_various_formats(self, input_str, expected):
        """参数化测试各种格式"""
        assert robust_json_parse(input_str) == expected
```

- **边界情况覆盖**：测试各种异常JSON格式、截断情况、特殊字符等。
- **Mock LLM响应**：创建Mock响应用于测试解析逻辑。
- **参数化测试**：使用 `@pytest.mark.parametrize` 减少重复代码。

3.6.3 解析性能优化

常见问题场景： 高并发场景下，JSON解析成为性能瓶颈。大量请求堆积导致响应延迟明显上升。

解决思路与方案：

```
import json
from functools import lru_cache

@lru_cache(maxsize=1024)
def cached_json_loads(json_str: str) -> dict:
    """缓存常用的JSON解析结果"""
    return json.loads(json_str)

class OptimizedParser:
    """优化的解析器"""

    def __init__(self):
        self._regex_cache = {}

    def parse(self, text: str) -> Optional[dict]:
        # 简单缓存：检测重复文本
        cache_key = hash(text)
        if cache_key in self._regex_cache:
            return self._regex_cache[cache_key]

        result = robust_json_parse(text)

        # 限制缓存大小
        if len(self._regex_cache) > 10000:
            self._regex_cache.clear()

        self._regex_cache[cache_key] = result
        return result
```

- **结果缓存**：对相同输入的解析结果进行缓存。
- **正则表达式预编译**：预编译正则表达式，避免重复编译开销。
- **流式解析优化**：对于大JSON，考虑使用ijson进行流式解析。

3.6.4 生产环境监控与告警

常见问题场景： 解析失败率突然上升，但运维团队没有及时发现。用户开始投诉"Agent完全不动了"，问题已经影响大量用户。

解决思路与方案：

```
import structlog

logger = structlog.get_logger()

class MonitoredParser:
    """带监控的解析器"""

    def __init__(self):
        self.success_count = 0
        self.fail_count = 0

    def parse(self, text: str) -> dict:
        try:
            result = robust_json_parse(text)
            self.success_count += 1
            return result
        except Exception as e:
            self.fail_count += 1
            # 记录失败日志
            logger.error(
                "parse_failed",
                error_type=type(e).__name__,
                error_message=str(e),
                text_preview=text[:100]
            )
            raise

    def get_metrics(self) -> dict:
        """暴露指标供监控系统采集"""
        total = self.success_count + self.fail_count
        success_rate = self.success_count / total if total > 0 else 0
        return {
            "parse_total": total,
            "parse_success": self.success_count,
            "parse_fail": self.fail_count,
            "parse_success_rate": success_rate
        }
```

- **解析成功率指标**：记录解析成功/失败次数。
- **错误分类统计**：分析不同类型的解析错误占比。
- **告警阈值**：当解析失败率超过阈值（如5%）时触发告警。

3.6.5 降级策略设计

常见问题场景： LLM输出格式完全失控，返回了大量无法解析的内容。服务进入完全不可用状态，没有任何兜底方案。

解决思路与方案：

```
class FallbackParser:
    """带降级策略的解析器"""

    def __init__(self, primary_parser, fallback_response: str = "抱歉，我无法理解您的请求"):
        self.primary_parser = primary_parser
        self.fallback_response = fallback_response

    def parse_with_fallback(self, text: str) -> dict:
        try:
            return self.primary_parser.parse(text)
        except Exception as e:
            logger.warning(f"主解析器失败，使用降级方案: {e}")

            # 降级方案1：尝试提取关键词
            keywords = self._extract_keywords(text)
            if keywords:
                return {
                    "action": "fallback_search",
                    "query": keywords
                }

            # 降级方案2：返回错误标记，触发重试流程
            return {
                "action": "error",
                "message": self.fallback_response,
                "needs_retry": True
            }

    def _extract_keywords(self, text: str) -> str:
        """从无法解析的文本中提取关键词"""
        import re
        # 简单实现：提取引号中的内容或英文单词
        matches = re.findall(r'"([^"]+)"', text)
        return matches[0] if matches else ""
```

- **多级降级**：设计多级降级策略，逐步放宽解析要求。
- **关键词提取**：当完全无法解析时，尝试提取关键词进行模糊搜索。
- **日志记录**：详细记录降级触发情况，便于后续分析改进。